Giả định và tính tải

Nguồn sự thật: sizing.py · token/model-call là giả định trước telemetry

Học viên: Trần Tuấn Tú · 2A202602840 | Đinh Ngọc Đức · 2A202602935 | Nguyễn Đình Phúc · 2A202602953
Nguyễn Việt Thành · 2A202602924 | Đoàn Tuấn Long · 2A202602609

1.760M
requests/tháng

2.376M
model calls

9.636B input
1.452B output

6.67 req/s
9.00 calls/s peak

6.100 GB
prod + stage

Công thức

2.000 DAU × 22 × 40 = 1.760.000 requests

Giờ hành chính = 220h
1.760.000 ÷ 792.000s = 2,22 req/s
×3 peak = 6,67 req/s

400.000 sandbox workload × 30s

Phạm vi

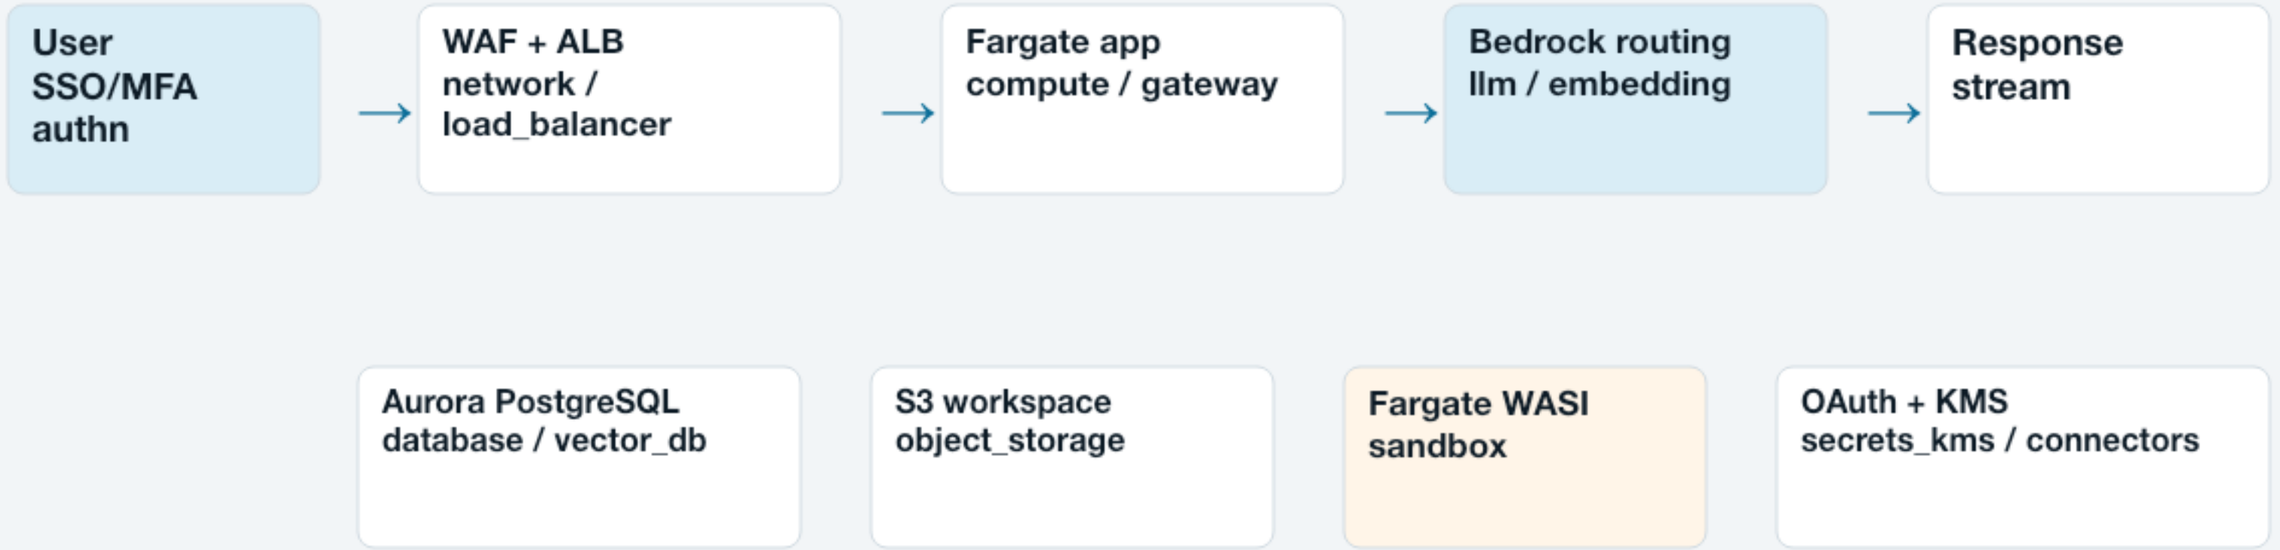
90.000 ảnh/tháng là volume riêng.

Production storage: 2.000 × 3 GB = 6.000 GB
Staging storage: 100 GB

Fargate billing theo lifetime; sandbox cost dùng handoff
Tú 80s billable giả định.

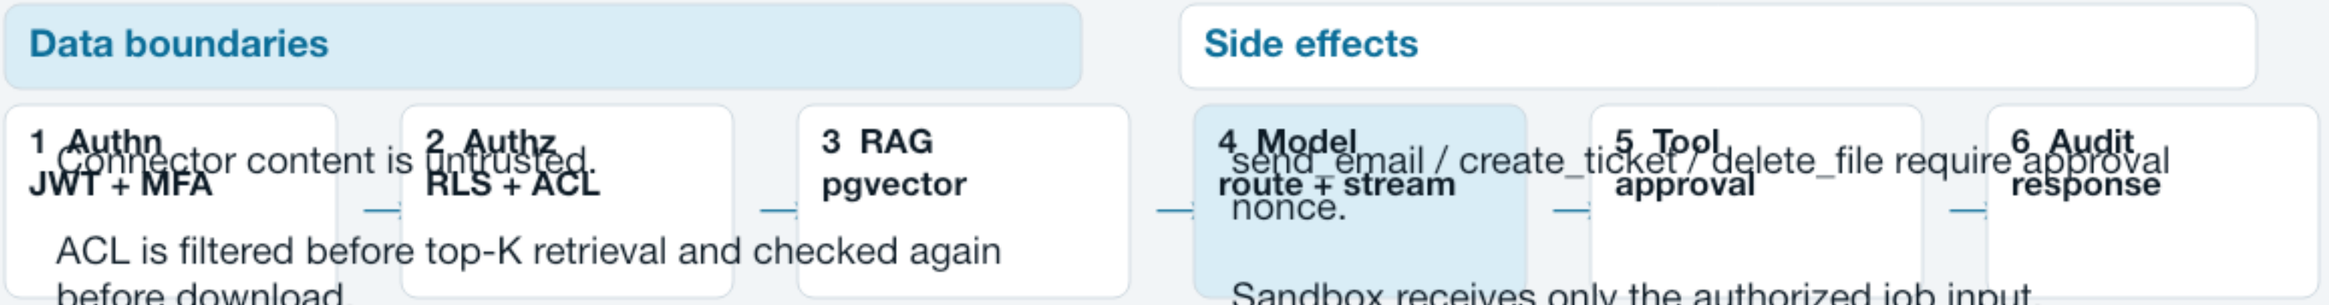
Kiến trúc tổng thể

Mỗi hộp gắn mã component của báo giá



Luồng xử lý một request

Một request có thể có nhiều LLM calls; tool call không tự sinh thêm LLM call



ACL is filtered before top-K retrieval and checked again before download.

OAuth token remains ciphertext; only broker can decrypt.

Sandbox receives only the authorized job input.

Audit records decision and actor without raw secrets.

Model routing và LLM serving

Baseline theo bảng giá Singapore do nhóm ghi nhận; chưa thay benchmark bằng giả định

Monthly token estimate

1 call/request
2.376B in · 316.8M out
Nova Micro: $316.81
Nova Lite C2/C3/C5: $605.17
Nova Pro: $4,675.97

1 call/request
1.760B in · 264M out

LLM subtotal: $5,452.37/month

C5 · Nova Lite: 1 text call/request · 484M input · 79.2M output · image call tách riêng

Known blocker

C3
2 calls/request
2.376B in · 369.6M out

3 calls/request
2.640B in · 422.4M out

90.000 images remain a requirement, but no production image model is included until a supported replacement is verified.

Vì sao API thay vì GPU/hybrid

Định hướng chi phí thấp nhất với tải bursty và chưa có throughput GPU đo được

Bedrock API · chọn baseline

- Không giữ GPU 24/7
- Chi phí gắn model calls/token
- Scale theo request và peak
- Private endpoint + APAC routing
- Dễ đổi model sau eval gate

GPU/hybrid · chưa chốt

- Cần giá GPU, throughput thực đo
- Phải cộng replica HA, model storage, network và 1–2 FTE
- Chưa có benchmark TTFT/quality
- Chỉ chọn khi total GPU < API và đạt H6/H8

Kết luận này là quyết định kiến trúc, chưa phải benchmark.

Model availability, data residency và pricing cần xác minh trong pilot Singapore

Connectors và phân quyền

Identity của user đi xuyên từ IdP đến DB, S3, vector và tool

Identity

Corporate IdP → Cognito federation → signed JWT

RBAC: employee / manager / admin
ABAC: tenant, department, classification

OAuth delegated scope tối thiểu; refresh token ciphertext trong DB.

Enforcement

PostgreSQL RLS không BYPASSRLS

S3 prefix: users/{user_id}/...

ACL trước vector top-K và trước presigned URL

Side effect cần approval nonce + re-authorize.

Workspace riêng và sandbox

Fargate + WASI guest: giới hạn capability thay vì tuyên bố zero-risk

400k production
20k staging
80s billable estimate

0.5 vCPU · 1 GB
120s hard timeout
1 MB output

No NAT/IGW
ECR/Logs/S3 endpoints
no task role

128 task peak
64 vCPU
quota ≥96 vCPU pending

Cùng task không phải security boundary: guest WASI không socket, không host path, không AWS credential. Code native/pip install runtime không nằm trong baseline; nếu cần phải báo giá lại Firecracker/Kata.

Sandbox cost: $287.46/month · endpoints riêng đã nằm trong sandbox, không cộng lại network.

AI governance và data governance

Guardrails Standard hỗ trợ tiếng Việt nhưng có xử lý cross-Region APAC

Before / after inference

Before: classification → DLP/PII → prompt attack → model

After: output guardrail → DLP → ACL → response

Connector data is untrusted; tool result gets separate prompt-attack check.

Human control

send_email / ticket / delete file:
proposal → payload hash → approval nonce → re-authz → execute

Audit 12 months Object Lock

No raw prompt, token, key in logs.

Governance + audit subtotal: $1,966.36/month · model/image inference charges are separate.

H4/H5 designed; guardrail language/residency and H8 safety still require pilot evidence

HA, backup và DR

Thiết kế multi-AZ; RTO/RPO là mục tiêu cần restore test

2 AZ
ALB + app

RDS PostgreSQL
Multi-AZ prod

S3 workspace
replica + Object Lock

Backup
restore drill

RTO 4h
RPO 1h

Thành subtotal: $1,436.46/month

No cross-Region DR cost is added to baseline; loss of Singapore requires a separate regional DR decision and price.

Status
Designed: multi-AZ, backup policy, restore path

Not verified: failover, restore timing, 99.5% availability under load

H7 is a design target until failover and restore drills complete

Monitoring và FinOps

Theo dõi usage ledger thay vì tạo 2.000 metric dimensions

Signals

TTFT p50/p95 · model calls · tokens
4xx/5xx/throttle · queue age
sandbox timeout/egress
ACL denies · KMS decrypt anomaly
Guardrail blocks · budget 50/80/100%

Cost controls

Usage ledger theo user/department

Quota theo user + unit

Giảm image/agent cấp cao trước

Không tắt DLP/audit khi vượt budget

Monitoring subtotal Tú: $25.26/month

Chi phí tháng

TOTAL khớp công thức SUM trong Excel; image generation chưa được cộng

LLM serving	$5,452.37
Tú: security/sandbox/ops	$2,321.63
Thành: data/cloud/DR	$1,436.46
Contingency 10%	$924.94
Embedding + gateway + licenses	$38.96
Ops labor	excluded
TOTAL	$10,174.36

$5.09 / DAU / month

Priced subtotal
$9,249.42

Contingency
$924.94

Image generation: 90k volume remains a blocker; Nova Canvas EOL means no unsupported $0.04/image charge is included.

Rủi ro, giới hạn kiểm chứng và mở rộng

Nộp được hai file; không biến mục tiêu thiết kế thành kết quả đo

Chưa thể xác minh

AWS account thực hành bị giới hạn Sydney; Singapore chưa chạy trực tiếp.

H6: chưa có TTFT p95 ≤3s benchmark.
H7: chưa có failover/restore drill.
H8: chưa có ≥95% quality report.

Image production model: blocker.

Khi lên 4.000 DAU

Requests, calls, tokens, storage, WAF/egress và guardrail text units tăng gần tuyến tính.

Review quota Fargate ≥96 vCPU, DB tier, queue, log budget.

Rerun sizing.py + cost workbook; re-evaluate API/GPU only with measured throughput.

Kết luận: architecture proposed for Singapore · cost working estimate · open verification items are explicitly listed.